Homework2：3D Moons 数据集的非线性分类研究

韩昌昊-23375152

实验主题：对比决策树、集成学习（AdaBoost）与支持向量机（SVM）在 3D 空间非线性流形数据上的分类性能。

1. 实验目的

1. 探究 Decision Tree 在 3D 空间中的切分逻辑及其对非线性边界的拟合能力。
2. 验证集成学习算法 AdaBoost 如何通过组合弱分类器提升模型泛化性能。
3. 对比 SVM 在不同核函数（Linear, Poly, RBF）下的空间映射能力与分类精度。
4. 通过 3D 决策曲面可视化，深入理解各算法的几何分类本质。

2. 数据集描述

数据形态：生成的 3D Make Moons 数据集，呈现两个相互交织的半月形（螺旋状）分布。

特征维度：3 维 (X, Y, Z)。

样本规模：训练集 2000 个样本，测试集 1000 个样本（C0 与 C1 各占 50%）。

噪声水平：设置 `noise=0.2`，模拟现实中数据重叠和干扰的情况。

3. 实验方法与模型设置

3.0 实验假设

设置：为了避免过拟合，同时直观比较各算法的效果，本实验对迭代轮次和深度进行归一化。

3.1 决策树 (Decision Tree)

设置：限制 `max_depth=5`。

逻辑：采用基于信息增益（Gini 系数）的轴平行切分。

3.2 AdaBoost + DecisionTrees

设置：以 `max_depth=5` 的决策树为基学习器，迭代次数 `n_estimators=100`，学习率 `0.1`。

逻辑：通过对分类错误样本增加权重，逐步修正边界误差。

3.3 支持向量机 (SVM)

实验选取了三种具有代表性的核函数：

1. Linear Kernel：尝试在 3D 空间寻找最优超平面。
2. Polynomial Kernel (degree=3)：通过三阶多项式特征映射进行非线性拟合。
3. RBF Kernel (Radial Basis Function)：利用高斯径向基函数，将数据映射到高维超平面，处理复杂的局部流形分布。

4. 实验结果对比

实验测试集共 1000 个样本（C0: 500 个，C1: 500 个）。根据程序实际运行输出，各模型的表现如下表所示：

4.1 综合性能统计表

算法模型	准确率 (Accuracy)	混淆矩阵 [TP,FP],[FN,TN]	结果分析
SVM (Linear)	**0.6770**	[[335, 165], [158, 342]]	**表现最差**。线性超平面无法切分交织的 3D 数据。
SVM (Polynomial)	**0.8600**	[[480, 20], [120, 380]]	具有一定曲面拟合力，但对 C1 类的召回率（Recall）较低。
Decision Tree	**0.8910**	[[459, 41], [68, 432]]	性能中等。轴平行切分在月牙边缘存在“锯齿状”误判。
AdaBoost + DT	**0.9610**	[[482, 18], [21, 479]]	**表现优秀**。通过集成学习显著修正了边界的分类错误。
SVM (RBF)	**0.9760**	[[485, 15], [9, 491]]	**性能最优**。平滑的非线性边

算法模型	准确率 (Accuracy)	混淆矩阵 [TP,FP],[FN,TN]	结果分析
			界最契合 3D 流形分布。

> 注：混淆矩阵格式说明：行代表真实类别 (0, 1)，列代表预测类别 (0, 1)。

4.2 各分类曲线划分示意图

下图依次是决策树、AdaBoost+决策树与 SVM 的分类曲线划分示意图。

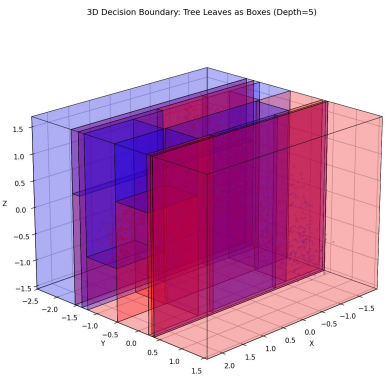

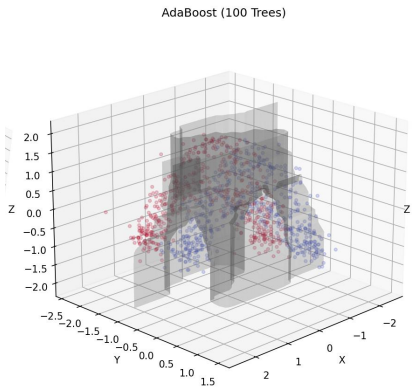

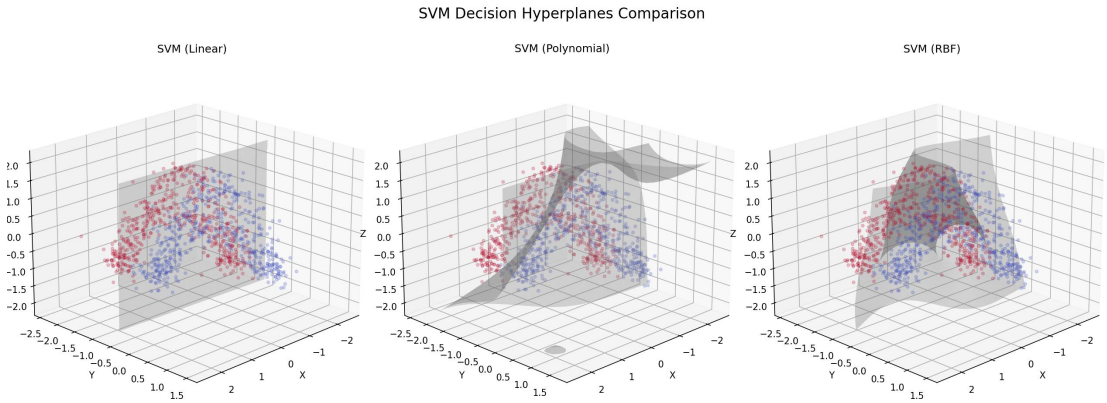

5. 讨论与分析：为什么某些算法表现更好？

5.1 SVM Linear: 0.6770

线性支持向量机（Linear SVM）在测试集上的准确率仅为 0.6770，表现出显著的欠拟合特征。从数学本质上看，线性核函数的假设空间仅限于R^3空间中的线性超平面 $f(x) = w^T x + b$。由于 3D Moons 数据集在拓扑结构上属于非线性交织流形，两类样本在欧几里得空间内并不存在线性可分的超平面。实验结果证

明，单纯依赖一阶线性判别函数无法捕捉复杂的数据分布，导致在两类月牙流形的重叠区域出现了大量的分类重叠。

5.2 决策树的轴平行切分与 Boosting 增强机制

单棵决策树的离散化约束 (DT: 0.8910)：决策树的底层逻辑是基于特征空间的递归二分，其决策边界本质上是由一系列轴平行的超平面组成的阶梯状分界面。由于模型必须通过离散的正交切分来逼近连续的弧形边界，这在几何上产生了明显的“阶梯效应”。混淆矩阵中 [41, 68] 的误判反映了单模型在处理非线性流形边缘时，因缺乏平滑度而导致的局部泛化失效。

AdaBoost 的加法模型与残差修正 (AdaBoost: 0.9610)：AdaBoost 通过前向分布算法构建加法模型，其决策边界是 100 棵弱分类器的加权组合。从几何角度看，AdaBoost 在 3D 空间内利用数以千计的微小切平面构建了一个高度复杂的非线性决策区域。这种集成机制通过对被误分类样本（即边缘噪声点）权重的动态调整，显著提升了模型对流形交界处细微特征的捕捉能力，从而增强了对噪声的鲁棒性。

5.3 RBF 核函数的核技巧与映射本质 (SVM RBF: 0.9760)

径向基核函数（RBF Kernel）在本次实验中表现出最优的泛化性能，其优势源于 RBF 核函数通过核技巧，隐式地将原始 3D 输入空间映射到无限维特征空间。在原始 3D 空间中，RBF 核的决策边界表现为基于样本相似度的连续、平滑超曲面。相比于决策树的离散切分，RBF 核利用径向对称性生成的“包围式”边界，能够更精准地还原 3D 月牙数据的几何流形。在存在 noise=0.2 的实验环境下，这种基于局部密度感知的平滑边界有效地缓解了过拟合风险，实现了最高的分类一致性。

6. 实验结论

1. 非线性数据首选 RBF SVM：实验证明，对于 3D Moons 这种具有明显几何流形特征的数据，基于距离相似度的 RBF 核函数具有天然的适配性。
2. 集成学习（AdaBoost）极具价值：即使基分类器（决策树）能力有限，通过集成学习也能在不改变模型性质的前提下，通过“群体决策”逼近最优性能。
3. 模型复杂度需与数据匹配：线性模型在此类问题上表现极差，说明在实

际应用中，识别数据的空间分布特征并选择合适的核函数或集成策略是分类任务成功的关键。