Homework3：LSTM 时序预测天气污染状况研究

韩昌昊-23375152

一、实验背景与实验内容

空气质量预测是环境科学与计算智能交叉领域的重要课题。由于 PM2.5 浓度不仅受到自身历史波动的约束，还与温度、湿度、降水规律存在复杂的非线性时空耦合关系，传统的线性回归或单纯的统计模型难以实现高精度的短期预报。

LSTM 网络凭借其独特的“门控”结构，能够有效提取时间序列中的长程依赖信息（图 1）。通过多变量建模，模型可以同时学习到气象因子与污染浓度之间的动态演化规律，为智慧城市环境预警提供科学的数据支撑。

本实验旨在构建一个基于 LSTM 的深度学习模型，用于预测城市空气质量中的 PM2.5 浓度。

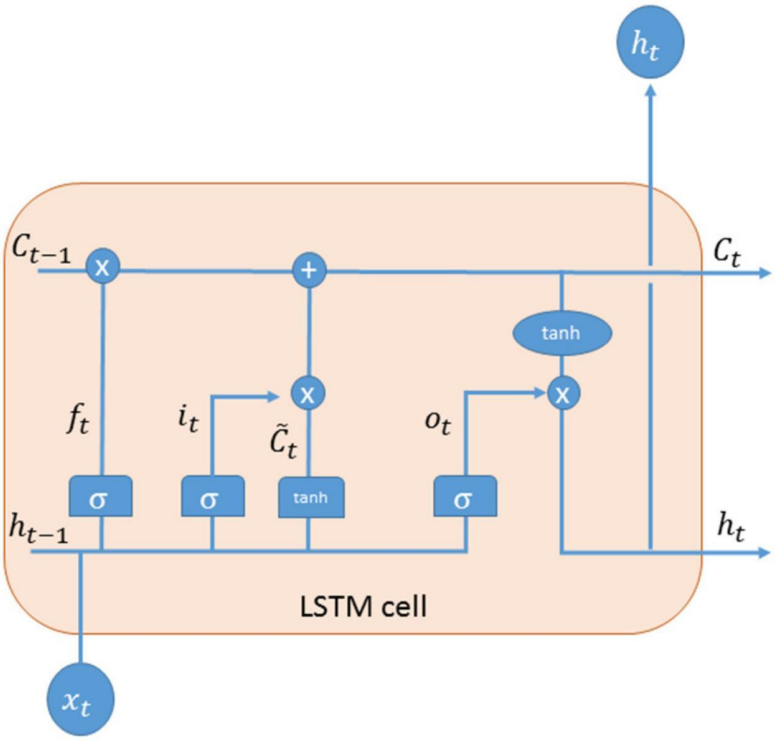

图 1　LSTM 原理示意图

二、实验数据

2.1 数据内容

本实验采用 Kaggle 上的空气质量数据集，数据内容来源于北京美国大使馆

的空气质量检测结果。该数据集包含 2010 年至 2014 年五年内逐小时的空气污染（PM2.5）浓度和气象数据。数据集共包含 13 个原始字段，涵盖了时间维度、空气质量指标以及多维度的气象参数。

根据模型输入与输出的设计，实验将数据划分为输入特征变量与输出结果两部分：

输出结果：pollution (PM2.5)：当前时刻的 PM2.5 浓度（ug/m^3），是模型的核心预测目标。

特征变量：dew (DEWP)：露点温度，反映空气湿度状况。temp (TEMP)：摄氏温度。press (PRES)：大气压力（hPa）。wnd_dir (cbwd)：组合风向（通过 LabelEncoder 转换为数值型特征）。wnd_spd (Iws)：累积风速（m/s）。snow (Is)：累积降雪小时数。rain (Ir)：累积降雨小时数。

2.2 数据预处理

1.时间序列索引：首先将日期列(date)转换为 datetime 类型，并设置为时间索引，保证数据的时序连续性。

2.缺失值处理：检查数据集中的缺失值情况，由于原始数据可能存在 NA 值，采用 fillna(0)填充为 0，避免模型输入出现空值。

3.风向编码：风向(wnd_dir)是类别型变量，使用标签编码（LabelEncoder）将其转换为数值形式，便于神经网络处理。

4.归一化：将所有特征使用 MinMaxScaler 缩放到[0,1]区间，使得不同量纲的特征具有可比性，有助于模型快速收敛。实践中，将整个数据集按行拼接，fit_transform 后得到缩放后的数组。

三、实验设置

为了让 LSTM 学习时序依赖，我们将多变量数据重构为监督学习格式滑动窗口。具体地，定义 look_back=12，表示用前 12 小时的数据预测第 13 小时的 PM2.5 浓度。通过遍历数据集构造样本，每个样本的输入 X[i]为第 i 时刻前 12 个时刻的所有特征值，输出 y[i]为第 i 时刻的污染值。经此转换后，数据维度为(7, 12, 1)，同时构造相应的一维目标序列。

四、模型架构与训练

（1）数据集划分：将构造好的序列数据按 80/20 比例划分为训练集和测试集，其中前 80%作为训练样本，后 20%用于评估模型泛化性能。

（2）网络结构：采用 Keras 构建堆叠式 LSTM 网络。模型由两层 LSTM 单元组成：第一层有 64 个单元且 return_sequences=True（返回序列输出），紧接一个 Dropout 层（比例 0.2）防止过拟合；第二层 LSTM 有 32 个单元，后接另一个 Dropout 层（0.2）。最后接一层全连接(Dense)输出单个值。这种双层 LSTM+Dropout 的结构能够提取长期时序特征并抑制过拟合，符合多维时间序列预测的常见做法。

（3）损失函数与优化器：模型使用平均绝对误差(MAE)作为损失函数，优化器采用 Adam。在训练过程中监控验证集的 MAE。

（4）早停策略：引入 EarlyStopping 回调，当验证损失在连续 5 个周期内无改善时停止训练，并恢复最优权重，以避免过拟合。早停能够自动截断冗余训练步骤，通常能提高模型的泛化能力。

（5）训练过程：在训练集上运行最多 20 个 epoch，批量大小为 64，不打乱时序（shuffle=False）。训练过程中记录训练损失和验证损失（MAE）曲线，用于后续分析。

五、预测与逆归一化

训练完成后，在测试集上进行预测，得到标准化尺度下的预测值 y_pred。由于我们对所有特征均进行了 MinMaxScaler 缩放，预测结果需要逆变换到原始量纲。方法如下：对于每个测试样本，取其最后一个时间步的其它特征（非污染值），将预测污染值与这些实际特征拼接成完整向量，然后整体应用 scaler.inverse_transform 逆缩放。最后提取逆缩放后的首列作为污染浓度的预测值 inv_y_pred；真实值 inv_y_test 同理处理。这样可以保证预测和实际都被还原到原始单位以计算指标。

六、实验结果

（1）损失曲线：训练过程中记录了训练集和验证集的损失曲线。观察到训练损失（MAE）随 Epoch 下降，验证损失趋于平稳或先下降后略微回升。早停

起到了抑制验证损失震荡的作用。

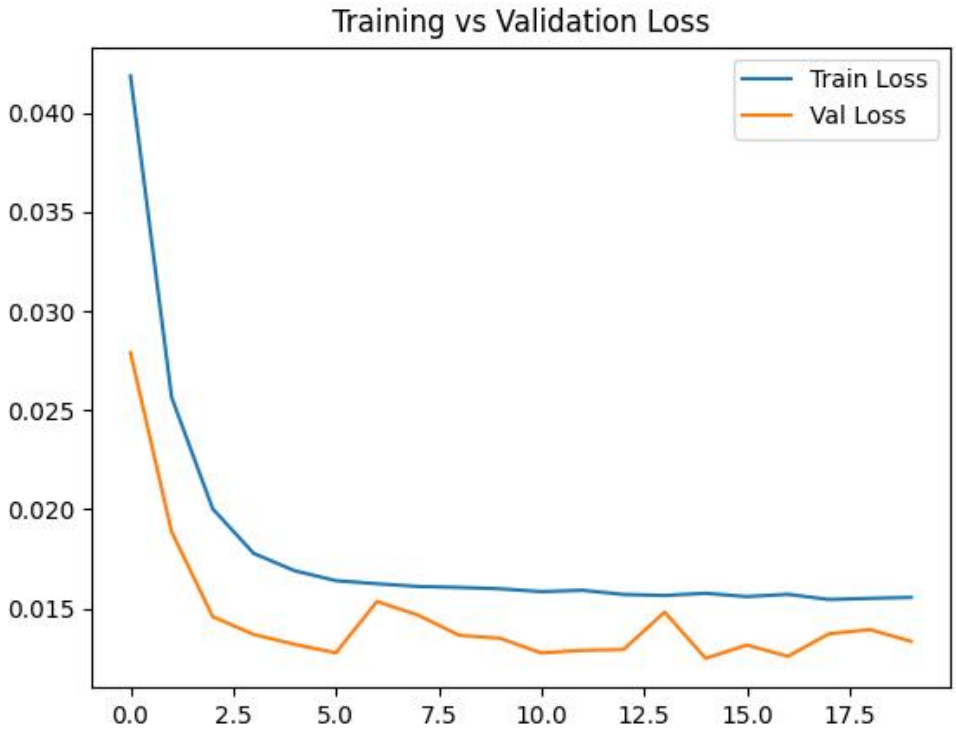

图 2 损失函数曲线

（2）性能指标：对测试集，计算预测值与真实值之间的均方根误差（RMSE）。RMSE 定义为$\sqrt{\frac{1}{N}\sum(y_i-\hat{y}_i)^2}$，能够直观衡量预测精度。实际运行中，我们得到如 Test RMSE: 24.17554555627605。

（3）预测效果：可视化全测试集和局部（前 200 个样本）的预测结果曲线，对比真实值与预测值。大致上，模型能够捕捉污染的主要波动趋势，但在某些尖峰区域误差较大。这与数据本身的噪声和 LSTM 的预测能力有关。

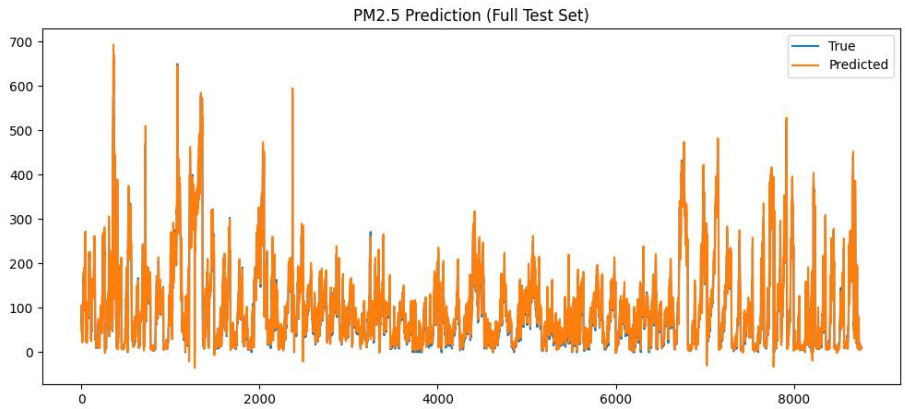

图 3 全局预测与真实值对比图

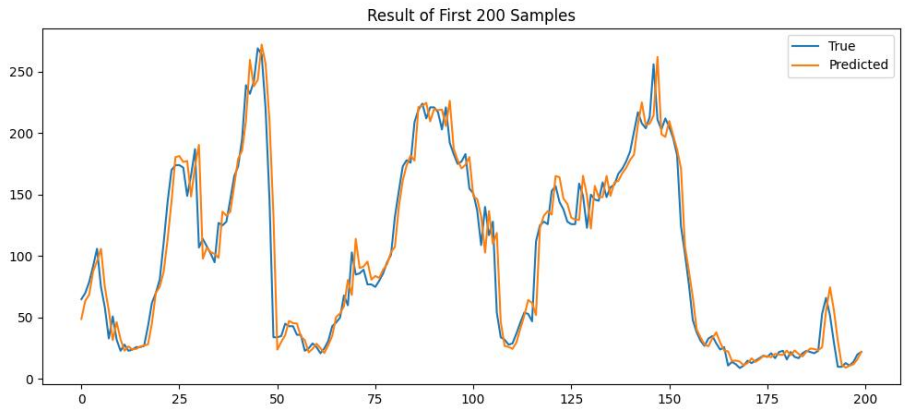

图 4 前 200 个样本预测与真实值对比图

（4）误差分布：将预测误差$\epsilon_i = y_i - \hat{y}_i$绘制直方图，可观察误差分布大致呈对称分布。误差的统计分析可指示模型的系统性偏差及改进方向。

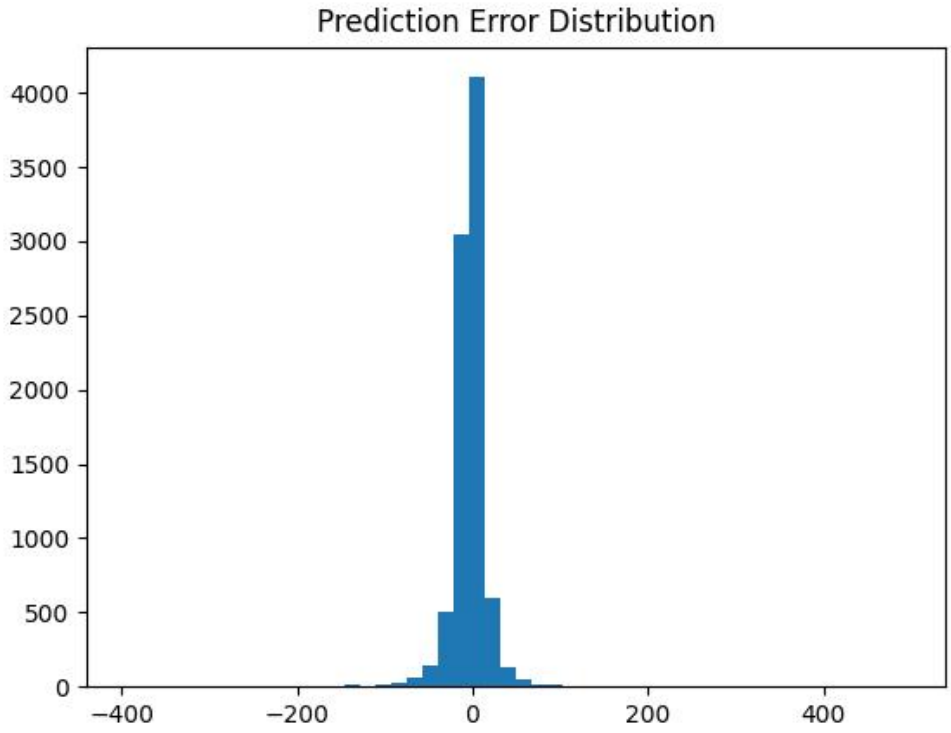

图 5 误差分布图

七、后续改进思路

（1）模型选择与超参数：本次实验采用了堆叠双层 LSTM 结构和 Dropout

正则化，这与常用实践一致。可尝试调整单层/多层、单元数或 Dropout 比例，以及更改损失函数比较效果差异。

（2）数据特征：当前使用了所有气象变量，但原始数据还包含年、月、日、小时等时间属性未直接利用。后续可考虑引入周期性时间特征（如一周周期、季节周期等）提高模型对长周期波动的感知。

（3）多步预测：本实验仅预测下一小时污染浓度，未来可扩展为多步预测，预测未来多小时的污染水平，以评估模型在更长时域上的性能。

八、实验结论

本实验验证了利用堆叠 LSTM 对多变量空气质量时间序列进行建模与预测的可行性。通过数据预处理、序列化处理和网络训练，模型能够在一定程度上准确预测未来污染水平。结果表明，该方法符合相关文献中对多变量时序预测的通用流程。基于实验观察，我们给出了若干改进方向以进一步提升模型性能。未来工作可通过更丰富的数据特征和先进的深度学习架构来持续优化预测效果。