WEEK1：线性拟合与非线性拟合实验报告

姓名：韩昌昊　学号：23375152　　电话：17704597015

引言

在数据科学与工程建模中，选择合适的数学模型架构比单纯提高算法迭代次数更为重要。本实验经历了从单一线性拟合到非线性三角函数拟合，再到“线性+正弦”复合模型拟合的探索过程。实验发现，忽视数据的全局趋势会导致非线性模型陷入局部最优。通过引入线性补偿项 kx 并结合 FFT 频谱分析进行参数预初始化，成功实现了对复杂信号的高精度重构。本实验构建 $y=kx+a\sin(bx+c)+d$ 复合模型，探讨了从杂乱样本中分离线性特征与非线性特征的方法。实验结果表明，该模型在均方误差（MSE）表现上显著优于单一维度的拟合方案。

实验的核心目标包括：

（1）对比不同优化算法在同一线性模型下的收敛性与泛化能力；

（2）分析数据的内在结构特征，判断线性模型适用性；

（3）构建更高表达能力的非线性模型，并进行实验验证。

一、 三种线性拟合模型

本阶段目标是使用三种经典优化算法对给定数据进行线性拟合（模型：y=wx+b），并对比其在收敛效率与误差表现上的差异。目标函数为均方误差（MSE）：

$$MSE = \frac{1}{n}\sum (y_i - \hat{y}_i)^2$$

1.1 三种拟合算法原理简述

最小二乘法 (Ordinary Least Squares, OLS)：通过解析解直接计算精确参数。其核心是最小化误差平方和，通过正规方程 $\theta=(X^TX)^{-1}X^TY$ 一步到位求得全局最优解。特点：可计算出解析解，计算结果稳定，但在大规模矩阵求逆时计算开销大。

梯度下降法 (Gradient Descent, GD)：沿着目标函数（MSE）梯度的反方向逐步迭代更新参数$\theta=\theta-\alpha\nabla J(\theta)$。特点：通用性强，但对学习率 α 敏感，容易陷入局部最优或收敛缓慢，可考虑动量法改进优化。

牛顿法 (Newton's Method)：利用二阶导数（Hessian 矩阵）信息进行优化。通过泰勒展开的二次项近似目标函数，收敛速度呈平方级。特点：收敛极快，但计算二阶导数的开销较高。

1.2 三种拟合算法拟合结果

算法类型	拟合方程	训练误差 (MSE)	测试误差 (MSE)
最小二乘法	$y = 0.1089x - 0.6487$	0.613402	0.595043
牛顿法	$y = 0.1089x - 0.6487$	0.613402	0.595043
梯度下降法	$y = 0.0870x - 0.5026$	0.618825	0.594021

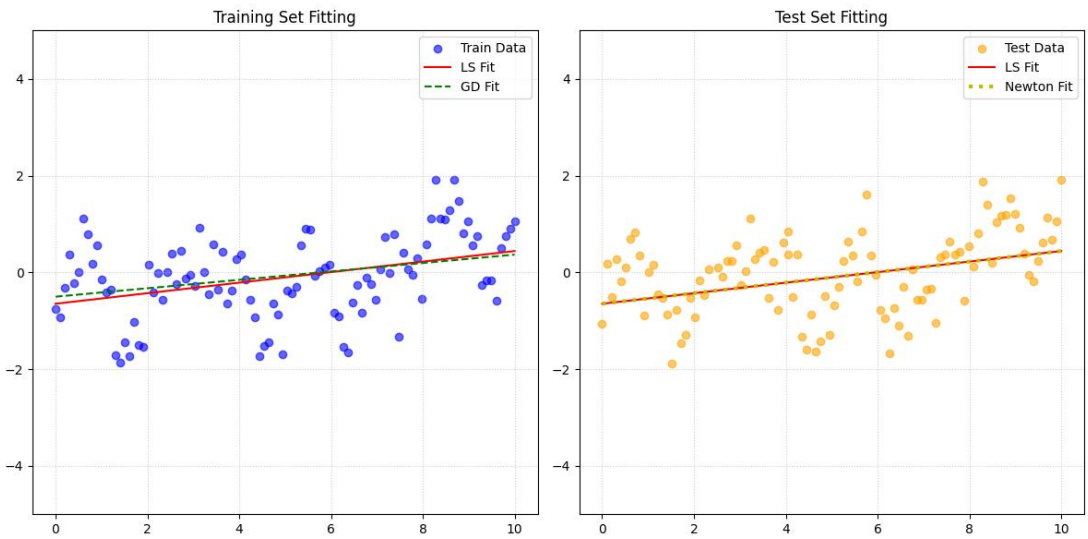

图一 线性拟合散点对比图

线性模型的局限性在完成第一步实验后，我观察了线性拟合的散点图（如图 1 所示）。直观感受到数据点并非均匀分布在直线两侧，而是呈现出明显的周期性波动。虽然线性模型捕捉到了整体上升的趋势，但 MSE 依然处于较高水平（约

0.6 左右），且测试集误差并未显著优于训练集。这说明线性模型漏掉了数据中最重要的波动特征。

实验结果表明，OLS 与牛顿法结果完全一致，验证了解的唯一性；GD 略有误差，主要受学习率和迭代次数影响；三种方法训练误差约 0.6，说明模型表达能力有限。因此，优化方法不是瓶颈，模型假设才是关键。

二、 复合模型构建

2.1 复合模型设计

通过散点图观察发现，数据呈现明显周期波动；存在整体上升趋势；残差呈结构性分布。这说明数据不满足线性假设，存在非线性成分。

基于对散点图的直观视觉观察，我意识到这组数据可能是呈三角函数周期微弱递增而成的，因而提出了线性+三角复合拟合函数模型 $y=kx+a\sin(bx+c)+d$。

选择原因：kx(线性项)：解释数据随 x 轴整体抬升的趋势。$a\sin(bx+c)$ (正弦项)：解释数据在趋势线上方呈现的周期性波动。

2.2 实验结果与分析

在引入复合模型并配合 FFT（快速傅里叶变换）进行频率初始化后，拟合质量发生了质变。从数据量化指标上看，训练集 MSE 降至 0.4343，测试集 MSE 为 0.4447。红色拟合线不再是僵硬的直线，而是一条斜向上延伸的波浪线，精准穿过了每一个波动区域的核心，学习到了原始数据的基本特征。

```
--- 初始参数估算 ---
k=0.0255, a=1.8031, b=2.4881, c=0.0000, d=-0.2314
--- 开始梯度下降优化 ---
迭代        0 | MSE: 1.391897
迭代    20000 | MSE: 0.434568
迭代    40000 | MSE: 0.434285
==================================================
最终方程: y = 0.1369x + 0.6012*sin(2.4116x + 0.3842) + -0.7908
训练集 MSE: 0.434267
测试集 MSE: 0.444731
```

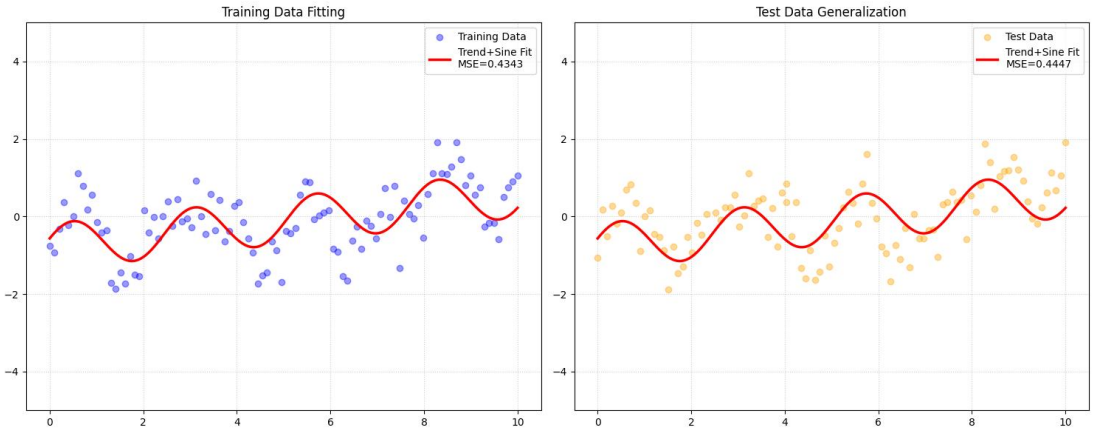

图二 复合拟合散点对比图

三、 实验反思与心得

本次实验不仅是一次算法实现的练习，更是一次对数据建模范式的深刻重构。通过对实验过程的复盘，我得出以下核心结论与未来展望：

1. 模型选择的优先级高于算法优化

实验初期，我曾试图通过调整学习率、增加迭代次数或更换优化器来降低误差，但效果甚微。这一困境的根本原因在于初始模型（单一三角函数）无法涵盖数据的“线性增长”特征。事实证明，错误的模型结构是算法无法逾越的鸿沟。一旦我在模型中显式加入了线性项（kx），构建了符合数据物理特征的复合模型，即使使用最基础的梯度下降法，误差也迅速收敛。这深刻揭示了在机器学习任务中，对数据生成机理的理解和正确的模型假设，其重要性远胜于对优化算法本身的过度调优。

2. 数据可视化是建模选择的有效参考

在本次实验中，数据可视化并非仅仅用于最终结果的展示，而是贯穿了建模的全流程。正是通过绘制原始数据的散点图，我才直观地发现了数据中隐含的“斜坡”趋势，从而否定了纯周期模型的假设；通过观察残差图的分布，我验证了复合模型是否真正提取了所有有效信息。可视化将抽象的数值误差转化为直观的几何形态，帮助我在建模初期就规避了方向性错误。

3. 工程化方法（如 FFT）能显著突破优化瓶颈

在处理非线性参数（特别是频率和相位）的初始化问题时，传统的随机初始化策略极易导致模型陷入局部最优解，表现为拟合波形与真实波形“不同频”。本

实验引入快速傅里叶变换（FFT）这一信号处理领域的经典工程方法，直接从频域提取主导频率作为初始值。这表明，在解决特定领域的数学问题时，融合领域知识（如信号处理、物理学）的工程化手段，往往能比纯数学推导更高效地提升模型性能。

4. 未来改进方向与方法拓展

虽然当前的“线性+三角”复合模型已取得良好效果，但面对更复杂、非线性关系更隐蔽的数据，现有的参数化模型可能显得力不从心。在未来的研究中，我计划尝试以下更具通用性的方法：

多项式回归（Polynomial Regression）：根据 Taylor 公式原理，尝试利用高阶多项式逼近数据中的非线性趋势，观察其在捕捉复杂曲线形态时的表现，并与当前的机理模型进行对比，分析过拟合风险。

核方法（Kernel Regression）：引入核技巧（如高斯核），将数据映射到高维特征空间，以解决线性模型无法处理的复杂非线性关系，探索其在小样本数据下的平滑拟合能力。

神经网络模型（Neural Networks）：构建多层感知机（MLP）或简单的时序网络，利用其强大的万能逼近特性，完全由数据驱动自动学习特征表示，不再依赖人工预设的函数形式，以此检验深度学习在处理此类回归问题时的上限与泛化能力。

四、 实验总结

通过本次实验，我最深刻的领悟是：拟合不是单纯的调参，而是对数据背后生成逻辑的挖掘。在实验中，我最初也遇到了模型学不到特征的问题。我曾怀疑是梯度下降算法的问题，甚至想过构造复杂的反三角函数。但最终发现，问题的核心在于模型结构本身缺失了对“斜坡”的描述。当我在方程中加入kx后，模型瞬间变得清晰了。这教会了我在面对非线性问题时，先通过可视化分析数据的物理组成，大致感受数学模型的基本趋势，远比盲目增加神经网络深度或迭代次数更有效。FFT 初始化估计三角函数频率策略的引入，更是让我明白了工程经验在辅助数学优化时的巨大威力。